Enstitü İstanbul İSMEK

İSMEK kursunda öğrendiğim bilgiler sayesinde geliştirdiğim

Fotoğraftan Element Analizi Projem

Fotoğraftaki nesneyi ve malzemesini tanıyıp içindeki tipik elementleri Türkçe açıklayan derin öğrenme sistemi

01 **Fotoğraf**
telefonla çekilen herhangi bir nesne

→

02 **Malzeme modeli**
kendi eğittiğim EfficientNetV2 · %79

→

03 **Nesne tanıma**
hazır MobileNetV2 1000 nesne

→

04 **Element bileşimi**
29 element tablosu + Türkçe açıklama

ÖRNEK · kendi telefonumun fotoğrafı



Model çıktısı: cep telefonu · 14 element

Al	alüminyum %15	Cu	bakır %10
Co	kobalt %5	Ni	nikel %1.5
Li	lityum %0.7	Sn	kalay %0.6
Ag	gümüş %0.1	Au	altın %0.03

%79 doğruluk

12 malzeme sınıfı

29 farklı element

Enstitü İstanbul İSMEK

Python ile Derin Öğrenme Tabanlı Görüntü ve Doğal Dil İşleme

Eğitmen: Cihan AYTAÇOĞLU

Proje: Ahmet ATAGÜL

KENDİ ÇEKTİĞİM FOTOĞRAFLAR · ÖRNEK 1/3

Cep telefonu

14 element: kobalt, lityum, gümüş, altın…

Cep telefonu



Nesne modeli: iPod / telefon (%66)
Malzeme modeli: plastik yüzey (%52)

Tipik bileşim: 14 element



Kendi eğittiğim malzeme modeli (EfficientNetV2, %79 doğruluk)
+ hazır nesne tanıma modeli (MobileNetV2).
Element oranları ölçüm değil; tanınan nesnenin/malzemenin tipik bileşimidir.

KENDİ ÇEKTİĞİM FOTOĞRAFLAR · ÖRNEK 2/3

Tornavida

çelik uç + plastik sap: demir, krom, vanadyum…

Tornavida



Nesne modeli: tornavida (%44)
Malzeme modeli: plastik sap (%72)

Tipik bileşim: 7 element



Kendi eğittiğim malzeme modeli (EfficientNetV2, %79 doğruluk)
+ hazır nesne tanıma modeli (MobileNetV2).
Element oranları ölçüm değil; tanınan nesnenin/malzemenin tipik bileşimidir.

KENDİ ÇEKTİĞİM FOTOĞRAFLAR · ÖRNEK 3/3

Kupa

seramik: oksijen, silisyum, alüminyum, potasyum…

Kupa



Nesne modeli: kupa (%55)
Malzeme modeli: seramik (%80)

Tipik bileşim: 5 element



Kendi eğittiğim malzeme modeli (EfficientNetV2, %79 doğruluk)
+ hazır nesne tanıma modeli (MobileNetV2).
Element oranları ölçüm değil; tanınan nesnenin/malzemenin tipik bileşimidir.

SONUÇ

Doğruluk: %59 → %79

MobileNetV2 + 600 resim → EfficientNetV2 + 2000 resim

%59
ilk deneme

%79
son model

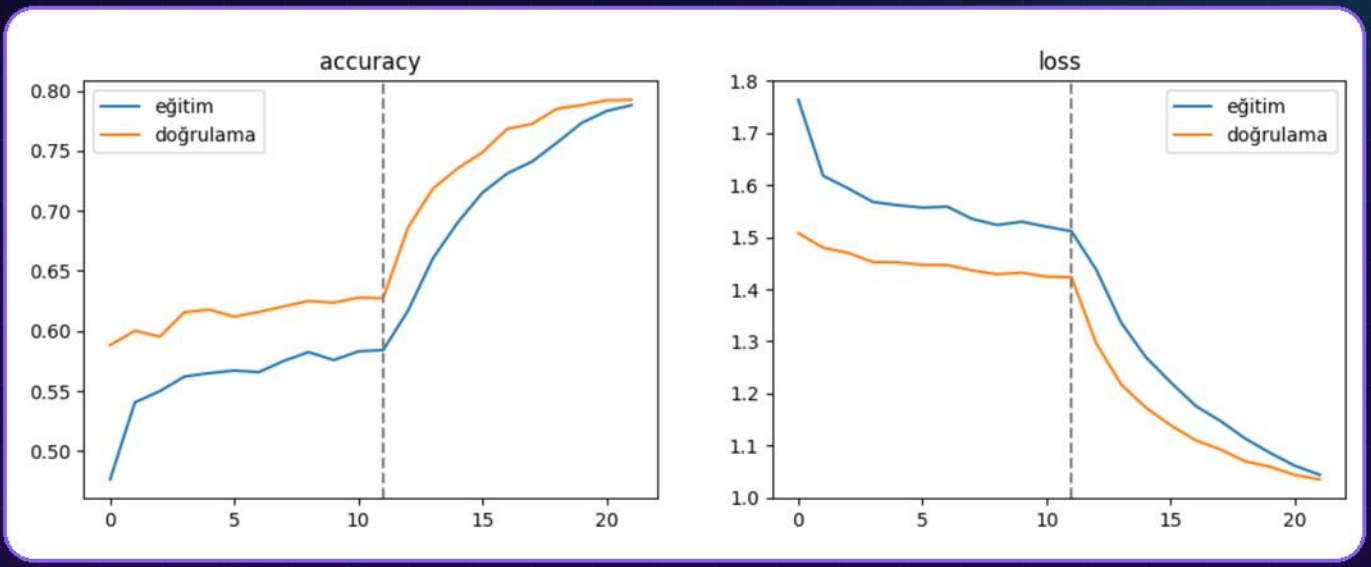
12
malzeme sınıfı

	precision	recall	f1-score	support
brick	0.90	0.83	0.87	405
ceramic	0.74	0.83	0.78	383
fabric	0.76	0.81	0.78	410
foliage	0.88	0.88	0.88	380
glass	0.74	0.72	0.73	357
leather	0.92	0.79	0.85	425
metal	0.69	0.68	0.68	400
paper	0.83	0.81	0.82	374
plastic	0.69	0.80	0.74	386
polishedstone	0.77	0.78	0.78	415
stone	0.80	0.86	0.83	421
wood	0.82	0.72	0.77	444
accuracy			0.79	4800
macro avg	0.80	0.79	0.79	4800
weighted avg	0.80	0.79	0.79	4800

EĞİTİM SÜRECİ

Transfer learning

önce üst katman, sonra fine-tuning (kesikli çizgi)



- ImageNet'te eğitilmiş EfficientNetV2B0 ile başladım
- Önce sadece sınıflandırma katmanını eğittim
- Sonra son 100 katmanı açıp küçük learning rate ile fine-tuning yaptım
- Augmentation, label smoothing ve EarlyStopping ekledim
- Doğrulama doğruluğu fine-tuning ile %63'ten %79'a çıktı

Teşekkürler

Bu projeyi Enstitü İstanbul İSMEK'te aldığım kursta öğrendiklerimle geliştirdim.

Enstitü İstanbul İSMEK

Python ile Derin Öğrenme Tabanlı Görüntü ve Doğal Dil İşleme

Eğitmen: Cihan AYTAÇOĞLU

Proje: Ahmet ATAGÜL

#DerinÖğrenme #GörüntüİşlemeYapayZeka #Python